

Big Data Course

Capstone Project Final Report

For students (instructor review required)

©2023 SAMSUNG. All rights reserved.

Samsung Electronics Corporate Citizenship Office holds the copyright of this document.

This document is a literary property protected by copyright law so reprint and reproduction without permission are prohibited.

To use this document other than the curriculum of Samsung Innovation Campus, you must receive written consent from copyright holder.

Algoritmos de Propiedad: ¿Cuál es el precio de la vivienda ideal?

(05/11/2024)

Data Hunters

Catalina Broughton
Felipe Osses
Sebastián Galindo
Alicia Morales

Content

1. Introduction

- 1.1. Background Information
- 1.2. Motivation and Objective
- 1.3. Members and Role Assignments
- 1.4. Schedule and Milestones

2. Project Execution

- 2.1. Simulated Scenario Description
- 2.2. Datasets Selection and Description
- 2.3. Data Ingestion Pipeline
- 2.4. Data Transformation Processing
- 2.5. Data Query and Insight

3. Results

- 3.1. Data Ingestion Scripts and Code
- 3.2. Data Transformation Scripts and Code
- 3.3. Description and Sample of Transformed Datasets
- 3.4. Data Visualization of Query Results

4. Projected Impact

- 4.1. Accomplishments and Benefits
- 4.2. Future Improvements

5. Team Member Review and Comment

6. Instructor Review and Comment

1. Introduction

1.1. Background Information

El mercado de la vivienda en Boston refleja una compleja interacción de factores que impactan en el valor de las propiedades, influido tanto por características ambientales como socioeconómicas. Boston, una de las ciudades más antiguas y densamente pobladas de los Estados Unidos, exhibe una alta demanda de viviendas debido a su actividad económica, histórica y educativa. Factores como la cercanía a zonas industriales, la presencia de instituciones educativas y el acceso a servicios públicos (incluyendo niveles de contaminación y tasas de criminalidad) juegan un papel fundamental en el costo de las propiedades. Además, indicadores específicos como el número promedio de habitaciones, el índice de urbanización de los barrios, la antigüedad de las edificaciones y los tipos de accesibilidad vial reflejan una variabilidad significativa en el valor del suelo urbano de la región.

Para realizar el estudio sobre el mercado inmobiliario de Boston, se escogió una data obtenida de Kaggle, comunidad especializada en la ciencia de datos que se dedica a recopilar y compartir información para el análisis de datos. Esta data consiste en 14 atributos y 509 instancias las cuales contienen información relevante referente a los valores de las viviendas en los suburbios de Boston.

Para el análisis utilizamos Python para poder trabajar los datos con la ayuda de bibliotecas bien conocidas en el mundo de la ciencia de datos, las cuales nos ayudaron en la recopilación, ordenamiento e interpretación de la información obtenida.

La ejecución de Python la llevaremos dentro de la herramienta Jupyter Notebook. La metodología incluirá un análisis exploratorio de los datos, para luego pasar por análisis de correlación, análisis univariado de variables, así como la implementación de un modelo regresivo y un modelo lineal.

1.2. Motivation and Objective

Para este proyecto buscamos principalmente entender y tener una visión completa de lo que implica el mercado inmobiliario en Boston.


Por medio de los conocimientos adquiridos durante el curso buscamos aplicar lo visto, con el objetivo de responder la hipótesis: “El precio de una propiedad depende de forma lineal del número de habitación y del índice de vulnerabilidad del sector”.

1.3. Members and Role Assignments:

- Sebastián Galindo: Análisis de datos y desarrollo de modelos.
- Felipe Osses: Recolección y limpieza de datos.
- Catalina Broughton: Visualización de datos y generación de informes.
- Alicia Morales: Coordinación del proyecto y presentación de resultados.

1.4. Schedule and Milestones:

Como equipo, definimos los roles individuales y planificamos cada fase del proyecto, estableciendo entregas parciales a través de una carta Gantt. Además, creamos un repositorio compartido en GitHub para gestionar los commits y registrar los avances de manera colaborativa.



2. Project Execution

2.1. Simulated Scenario Description

El conjunto de datos de viviendas de Boston contiene 509 filas y 14 columnas, e incluye datos sobre diversas características de las viviendas residenciales en el área de Boston para el análisis y modelado de regresión. Para esta simulación, se asume que los indicadores socioeconómicos y ambientales (como la tasa de criminalidad, la concentración de óxidos de nitrógeno y el acceso a carreteras) se mantienen estables durante el período de análisis. También se considera que los valores históricos de estos indicadores reflejan adecuadamente las condiciones actuales del mercado inmobiliario. Además, se establece la hipótesis de que existe una relación lineal entre los factores seleccionados y el valor medio de las viviendas, lo cual permite emplear técnicas de regresión para la predicción de precios.

2.2. Datasets Selection and Description

El dataset analiza los valores de viviendas en los suburbios de Boston, utilizado previamente en estudios significativos de análisis de regresión y diagnóstico de modelos, como en "Regression Diagnostics" de Belsley, Kuh y Welsch (1980), y en investigaciones sobre técnicas de aprendizaje mixto por Quinlan (1993).

Número de instancias: 509

Número de columnas: 14

Descripción de la DataSet:

- CRIM: tasa de criminalidad per cápita por ciudad.
- ZN: proporción de tierra residencial zonificada para lotes de más de 25.000 pies cuadrados.
- INDUS: Proporción de negocios no-retail por sector.
- CHAS: variable ficticia de Charles River (= 1 si el lote limita con el río; 0 en caso contrario).
- NOX: concentración de óxidos nítricos (partes por 10 millones).
- RM: número promedio de habitaciones por vivienda.
- AGE: proporción de unidades ocupadas por sus propietarios construidas antes de 1940.
- DIS: Distancias ponderadas a cinco centros de empleo de Boston
- RAD: Índice de accesibilidad a carreteras radiales
- TAX: Tasa de impuesto a la propiedad de valor total por \$ 10,000
- PTRATIO: Proporción alumno-profesor por ciudad.
- B: $1000(B_k - 0,63)^2$ donde B_k es la proporción de negros por ciudad.
- LSTAT: Porcentaje de la población con menor estatus.
- MEDV: Valor medio de las viviendas en 1000 US

2.3. Data Ingestion Pipeline

Para la ingestión de datos, los datos fueron obtenidos del repositorio público de Kaggle y se almacenaron en un formato CSV. Utilizando bibliotecas de Python como pandas, el conjunto de datos almacenado en Google Drive, fue cargado en un DataFrame para su manipulación y análisis.

2.4. Data Transformation Processing

Antes de partir con el procesamiento de datos, se revisará que la base de datos escogida no tuviera valores nulos como también entender que tipo de dato era el contenido, para ellos se ocupará Pandas para la revisión de los datos.

- **Verificación y Limpieza del Dataset:** Se verificó la integridad del conjunto de datos y se identificaron valores faltantes o inconsistencias, asegurando que el dataset estuviera limpio y listo para el análisis.
- **Relleno de Valores Nulos:** Los valores faltantes en algunas columnas se reemplazaron con ceros, permitiendo trabajar con un dataset completo sin datos incompletos que afectaran el análisis.

- **Conversión de Variables Categóricas:** Las columnas CHAS y RAD fueron transformadas de valores numéricos a texto, lo cual permite interpretarlas como categorías en lugar de variables continuas.
- **Visualización de la Matriz de Correlación:** Se generó una matriz de correlación para observar relaciones entre variables y decidir cuáles podrían ser más relevantes o requerir transformaciones adicionales en el análisis.

Estas transformaciones y verificaciones aseguraron que el conjunto de datos estuviera listo para un análisis estadístico riguroso.

2.5. Data Query and Insight

Para interpretar adecuadamente los datos, se realizó un análisis exploratorio enfocado en variables clave como el número de habitaciones (RM), la tasa de criminalidad (CRIM), la cercanía al río Charles (CHAS), el acceso a carreteras (RAD), la proporción de población de bajo estatus socioeconómico (LSTAT) y el valor de las viviendas (MEDV).

Se llevaron a cabo consultas y filtrados específicos, agrupando los datos y calculando promedios para observar patrones relevantes. Adicionalmente, se exploraron relaciones importantes entre variables, como la influencia del tamaño de la vivienda y la criminalidad en los valores inmobiliarios.

Este análisis incluyó una correlación de los datos, lo cual fue fundamental para el modelo de regresión lineal, ajustando el modelo según fuera necesario y concluyendo con un análisis residual.

Los insights obtenidos destacan factores determinantes, como la cantidad de habitaciones, el acceso a carreteras y la tasa de criminalidad, los cuales afectan significativamente los precios de las propiedades, proporcionando una base para estrategias de valoración de inmuebles y posibles mejoras en políticas urbanas.

3. Results

3.1. Data Ingestion Scripts and Code

```

import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
import statsmodels.formula.api as smf
import statsmodels.tools.eval_measures as metrics

```

```

[ ] file_path = 'https://drive.google.com/uc?id=16g-VsVZVTvy1QZljY1bZEwvFcsT3CS2v'
# df = pd.read_csv(file_path, sep = ',')
df = pd.read_csv(file_path, sep=',', on_bad_lines='skip')

```

```

[ ] # visualización inicial de una muestra del set de datos
df.sample(5)

```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
94	0.04294	28.0	15.04	0.0	0.464	6.249	77.3	3.6150	4.0	270.0	18.2	396.90	10.59	20.6
446	6.28807	0.0	18.10	0.0	0.740	6.341	96.4	2.0720	24.0	666.0	20.2	318.01	17.79	14.9
423	7.05042	0.0	18.10	0.0	0.614	6.103	85.1	2.0218	24.0	666.0	20.2	2.52	23.29	13.4
107	0.13117	0.0	8.56	0.0	0.520	6.127	85.2	2.1224	5.0	384.0	20.9	387.69	14.09	20.4
57	0.01432	100.0	1.32	0.0	0.411	6.816	40.5	8.3248	5.0	256.0	15.1	392.90	3.95	31.6

```

[ ] # dimensión del set de datos
df.shape

```

```

(506, 14)

```

3.2. Data Transformation Scripts and Code

✓ Análisis Exploratorio

Haz doble clic (o pulsa Intro) para editar

```
[ ] df.sample(5)
```



	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
214	0.28955	0.0	10.59	0.0	0.489	5.412	9.8	3.5875	4.0	277.0	18.6	348.93	29.55	23.7
275	0.09604	40.0	6.41	0.0	0.447	6.854	42.8	4.2673	4.0	254.0	17.6	396.90	2.98	32.0
337	0.03041	0.0	5.19	0.0	0.515	5.895	59.6	5.6150	5.0	224.0	20.2	394.81	10.56	18.5
315	0.25356	0.0	9.90	0.0	0.544	5.705	77.7	3.9450	4.0	304.0	18.4	396.42	11.50	16.2
56	0.02055	85.0	0.74	0.0	0.410	6.383	35.7	9.1876	2.0	313.0	17.3	396.90	5.77	24.7

- El dataset tiene 506 filas y 14 columnas.
- Cada fila tiene valores para 14 variables como CRIM, ZN, INDUS, etc.
- La columna objetivo es MEDV, que representa el valor mediano de las casas (en miles de dólares).
- Las filas seleccionadas muestran los valores de estas 14 variables para ciertas observaciones de casas en el dataset.

```
[ ] # No hay valores nulos en el set de datos
# Todas las variables son de tipo numéricas
df.info()
```



```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 506 entries, 0 to 505
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype
---  ---
0    CRIM        506 non-null    float64
1    ZN          506 non-null    float64
2    INDUS       506 non-null    float64
3    CHAS        506 non-null    float64
4    NOX         506 non-null    float64
5    RM          506 non-null    float64
6    AGE         506 non-null    float64
7    DIS         506 non-null    float64
8    RAD         506 non-null    float64
9    TAX         506 non-null    float64
10   PTRATIO     506 non-null    float64
11   B           506 non-null    float64
12   LSTAT       506 non-null    float64
13   MEDV       506 non-null    float64
dtypes: float64(14)
memory usage: 55.5 KB
```

- **Non-Null Count: 506 non-null:** Muestra que no hay valores nulos en ninguna de las columnas, lo que es positivo porque significa que todos los datos están completos.
- **Dtype: float64:** Indica que todas las columnas son de tipo número de punto flotante (decimales), lo que sugiere que estás trabajando con datos continuos.
- El conjunto de datos está limpio (sin valores nulos) y todas las variables son numéricas

```
[ ] df.describe()
```



	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
count	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000
mean	3.613524	11.363636	11.136779	0.069170	0.554695	6.284634	68.574901	3.795043	9.549407	408.237154	18.455534	356.674032	12.653063	22.532806
std	8.601545	23.322453	6.860353	0.253994	0.115878	0.702617	28.148861	2.105710	8.707259	168.537116	2.164946	91.294864	7.141062	9.197104
min	0.006320	0.000000	0.460000	0.000000	0.385000	3.561000	2.900000	1.129600	1.000000	187.000000	12.600000	0.320000	1.730000	5.000000
25%	0.082045	0.000000	5.190000	0.000000	0.449000	5.885500	45.025000	2.100175	4.000000	279.000000	17.400000	375.377500	6.950000	17.025000
50%	0.256510	0.000000	9.690000	0.000000	0.538000	6.208500	77.500000	3.207450	5.000000	330.000000	19.050000	391.440000	11.360000	21.200000
75%	3.677083	12.500000	18.100000	0.000000	0.624000	6.623500	94.075000	5.188425	24.000000	666.000000	20.200000	396.225000	16.955000	25.000000
max	88.976200	100.000000	27.740000	1.000000	0.871000	8.780000	100.000000	12.126500	24.000000	711.000000	22.000000	396.900000	37.970000	50.000000

- Las siguientes líneas presentan estadísticas para cada columna numérica.
- **count:** El número de entradas en cada columna. Aquí, todos los valores son 506, lo que confirma que no hay datos faltantes en ninguna columna.
- **mean (promedio):** Representa el valor promedio de cada columna.
- **std (desviación estándar):** Mide la dispersión de los datos respecto a la media.

3.3. Description and Sample of Transformed Datasets

▼ Análisis univariado de MEDV (valor de la vivienda)


Veremos la relación de estas categoría con el precio de las propiedades

```
[ ] df.MEDV.describe()
```

```
count    506.000000
mean      22.532806
std        9.197104
min         5.000000
25%       17.025000
50%       21.200000
75%       25.000000
max       50.000000
Name: MEDV, dtype: float64
```


```
[ ] sns.boxplot(data=df, x='MEDV')
```

```
<Axes: xlabel='MEDV'>
```



```
[ ] sns.displot(data=df, x='MEDV', kind='kde')
```

```
<seaborn.axisgrid.FacetGrid at 0x19563029750>
```



```
# Límite superior
q1 = df['MEDV'].quantile(.25)
q2 = df['MEDV'].quantile(.5)
q3 = df['MEDV'].quantile(.75)
RIQ = q3-q1
print("Rango Inter cuartil:", RIQ)
print("q1:", q1)
print("q2:", q2)
print("q3:", q3)
ls_MEDV = q3 + 1.5*RIQ
print("límite superior:", ls_MEDV)
```


```
Rango Inter cuartil: 7.975000000000001
q1: 17.025
q2: 21.2
q3: 25.0
límite superior: 36.962500000000006
```

Podemos ver que es más probable encontrar precios entre 10 mil y 30 mil USD. Sin embargo, hay valores atípico que exceden del rango normal de precios (límite superior = 36.96)

Veamos como se relacionan nuestra categoría CHAS con los precios


```
[ ] sns.displot(data=df, x='MEDV', kind='kde', hue='CHAS')
```

```
<seaborn.axisgrid.FacetGrid at 0x19562da0580>
```



```
[ ] sns.violinplot(data=df, x='CHAS', y='MEDV')
```

```
<Axes: xlabel='CHAS', ylabel='MEDV'>
```




```
[ ] df.groupby('CHAS')['MEDV'].describe()
```

	count	mean	std	min	25%	50%	75%	max
CHAS								
0.0	471.0	22.093843	8.831362	5.0	16.6	20.9	24.80	50.0
1.0	35.0	28.440000	11.816643	13.4	21.1	23.3	33.15	50.0

Notamos que el índice 1 (la propiedad limita con el río) tiende a tener precios medios más elevados y más dispersos. Las viviendas que no limitan con el río tienden a tener precios más uniformes. En ambos casos, el precio máximo alcanza los 50 mil dólares. Por otro lado, la probabilidad de encontrar propiedades que limiten con el río, es mucho menor.

Veamos el caso de RAD con los precios

```
[ ] plt.figure(figsize=(13, 6))
sns.violinplot(data=df, x='RAD', y='MEDV')
plt.show()
```



3.4. Data Visualization of Query Results

Modelo Regresivo

A continuación analizaremos la relación entre el precio, el número de habitaciones, y porcentaje de menor status de la población. Contestaremos las siguientes preguntas:


- ¿Existe relación entre el precio y el número de habitaciones?
- ¿Existe relación entre el precio y el índice de vulnerabilidad?
- De existir relación, ¿tiene comportamiento lineal?
- ¿Podemos realizar un modelo predictivo para el precio con las demás variables?
- ¿Cuán buena podría ser esa predicción?

Hipótesis de trabajo


El precio de una propiedad depende de forma lineal del número de habitaciones y del índice de vulnerabilidad del sector

```
[ ] # La representación visual entre el índice y el precio, nos muestra una relación
# lineal decreciente
sns.scatterplot(data=df, x='LSTAT', y='MEDV')
```

<Axes: xlabel='LSTAT', ylabel='MEDV'>



```
# La representación visual entre el numero de habitaciones y el precio, nos muestra una relación
# lineal creciente
sns.scatterplot(data=df, x='RM', y='MEDV')
```



✓ Selección de predictores

```
[ ] df[['MEDV', 'LSTAT', 'RM']].corr()
```

	MEDV	LSTAT	RM
MEDV	1.000000	-0.737663	0.695360
LSTAT	-0.737663	1.000000	-0.613808
RM	0.695360	-0.613808	1.000000

- Si bien existe una correlación entre LSTAT y RM, es de fuerza media, por lo tanto descartamos multicolinealidad

- Ajustaremos primeramente un modelo lineal con la LSTAT, ya que tiene mayor correlación (-0.74)

✓ Ajuste del modelo lineal

```
[ ] lm = smf.ols(data=df, formula='MEDV ~ LSTAT').fit()
```

```
[ ] lm.params
```

```
Intercept    34.553841
LSTAT        -0.950049
dtype: float64
```

```
[ ] lm.summary()
```

```
OLS Regression Results
Dep. Variable: MEDV      R-squared:  0.544
Model: OLS              Adj. R-squared: 0.543
Method: Least Squares   F-statistic: 601.6
Date: Thu, 22 Aug 2024  Prob (F-statistic): 5.08e-88
Time: 03:29:01          Log-Likelihood: -1641.5
No. Observations: 506   AIC: 3287.
Df Residuals: 504      BIC: 3295.
Df Model: 1
Covariance Type: nonrobust
```

	coef	std err	t	P> t	[0.025 0.975]
Intercept	34.5538	0.563	61.415	0.000	33.448 35.659
LSTAT	-0.9500	0.039	-24.528	0.000	-1.026 -0.874
Omnibus:	137.043		Durbin-Watson:	0.892	
Prob(Omnibus):	0.000		Jarque-Bera (JB):	291.373	
Skew:	1.453		Prob(JB):	5.36e-64	
Kurtosis:	5.319		Cond. No.	29.7	

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Los parámetros nos indican que:

- El aumento de 1 unidad en el índice LSTAT está asociado a la disminución de 950 dólares
- los P value de la variable predictora se encuentran por debajo del nivel de significancia (0.05), por lo tanto se mantiene en el modelo
- Nuestro modelo es capaz de explicar el 54,3% de la variabilidad.

```
[ ] lm2 = smf.ols(data=df, formula='MEDV ~ LSTAT + RM').fit()
```

```
[ ] lm2.params
```

```
Intercept    -1.358273
LSTAT        -0.642358
RM           5.094788
dtype: float64
```

```
[ ] lm2.summary()
```

```
OLS Regression Results
Dep. Variable: MEDV      R-squared: 0.639
Model: OLS              Adj. R-squared: 0.637
Method: Least Squares   F-statistic: 444.3
Date: Thu, 22 Aug 2024   Prob (F-statistic): 7.01e-112
Time: 03:29:01          Log-Likelihood: -1582.8
No. Observations: 506    AIC: 3172.
Df Residuals: 503        BIC: 3184.
Df Model: 2
Covariance Type: nonrobust

coef    std err    t    P>|t| [0.025 0.975]
Intercept -1.3583  3.173   -0.428  0.669 -7.592  4.875
LSTAT    -0.6424  0.044  -14.689  0.000 -0.728 -0.556
RM       5.0948  0.444   11.463  0.000  4.222  5.968
Omnibus: 145.712   Durbin-Watson: 0.834
Prob(Omnibus): 0.000   Jarque-Bera (JB): 457.690
Skew: 1.343         Prob(JB): 4.11e-100
Kurtosis: 6.807       Cond. No. 202.
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

- Podemos observar que ambos p values se encuentra por debajo de 0.05 y que a su vez el R2 ajustado aumenta 0.637 respecto del modelo anterior, siendo un modelo más robusto.
- El aumento de 1 unidad en el índice LSTAT está asociado a la disminución de 642 dólares
- Por cada dormitorio adicional el precio de la propiedad aumenta en 5100 dólares

✓ Métricas de evaluación del modelo


```
[ ] y_true = df['MEDV']
y_pred = lm2.predict(df[['LSTAT', 'RM']])
print('MAE: {}'.format(metrics.meanabs(y_true, y_pred)))
print('MSE: {}'.format(metrics.mse(y_true, y_pred)))
print('RMSE: {}'.format(metrics.rmse(y_true, y_pred)))
print('R2: {}'.format(lm2.rsquared))
print('R2-Adj: {}'.format(lm2.rsquared_adj))
```

```
MAE: 3.952580067119268
MSE: 30.51246877729947
RMSE: 5.523809263298243
R2: 0.6385616062603404
R2-Adj: 0.6371244754701231
```

Con lo anterior, podemos realizar un predicción del precio de una propiedad tomando LSTAT y RM, y esperar un error absoluto medio de 3953 dólares.


```
[ ] plt.scatter(y_true,y_pred)
plt.xlabel('Y Real')
plt.ylabel('Predicción Y')
```

```
Text(0, 0.5, 'Predicción Y')
```



```
[ ] plt.scatter(y_true, y_pred)
plt.xlabel('Precio Real')
plt.ylabel('Precio Predicho')
plt.title('Precio Real vs Precio Predicho')
plt.plot([y_true.min(), y_true.max()], [y_true.min(), y_true.max()], 'r--', lw=2)
plt.show()
```


```
Text(0, 0.5, 'Predicción Y')
```



✓ Análisis de Residuales

```
[ ] # Con este gráfico comprobamos que el error se distribuye de forma normal
(y_pred - y_true).plot(kind='kde')
```

```
>>> <Axes: ylabel='Density'>
```



```
[ ] sns.histplot(y_pred - y_true)
```

```
>>> C:\Users\Equipo\AppData\Local\Temp\ipykernel_21480\2386858460.py:1: UserWarning:
```


`distplot` is a deprecated function and will be removed in seaborn v0.14.0.

Please adapt your code to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).

For a guide to updating your code to use the new functions, please see <https://gist.github.com/mwaskom/de44147ed2974457ad6372750bbe5751>

```
sns.distplot(y_pred - y_true)
```

```
<Axes: ylabel='Density'>
```



Se observa que los residuos se distribuyen de forma normal. Y su centro se encuentra cercano al valor 0, por lo que se deduce que el modelo lineal representa la variable que se quiere estudiar.

4.1. Accomplishments and Benefits

Accomplishments

El análisis estadístico realizado en este estudio ha permitido identificar y comprender mejor los factores que influyen en el valor medio de las propiedades (MEDV) en diversas áreas urbanas. Utilizando técnicas como el análisis de correlación y modelos de regresión, se ha logrado:

- Determinar las variables con mayor influencia en los precios de las propiedades, como la tasa de criminalidad (CRIM), la concentración de óxidos de nitrógeno (NOX), y el número de habitaciones promedio (RM).

- Construir un modelo predictivo inicial capaz de estimar el valor de una propiedad en función de variables demográficas y socioeconómicas, proporcionando una herramienta valiosa para la predicción de precios en el mercado inmobiliario.
- Visualizar patrones y relaciones entre variables clave mediante gráficos y diagramas, facilitando la interpretación de los resultados para la toma de decisiones.

Benefits

Este análisis proporciona varias ventajas tanto para los profesionales del sector inmobiliario como para los investigadores:

- **Mejor toma de decisiones:** Con una comprensión más clara de los factores que impactan en los precios, los inversores y agentes inmobiliarios pueden tomar decisiones informadas sobre las propiedades en las que desean invertir o desarrollar.
- **Valoración precisa:** Los modelos predictivos ayudan a ofrecer valoraciones de propiedades más precisas, adaptadas a las condiciones socioeconómicas y demográficas de cada área.
- **Contribución a la política pública:** Identificar la influencia de factores como la polución o la criminalidad en los precios de las propiedades también puede guiar a los responsables de políticas públicas a mejorar ciertas condiciones urbanas que afectan el bienestar de los habitantes.

El modelo predictivo desarrollado ofrece una herramienta útil para estimar precios de manera precisa, facilitando la toma de decisiones en el sector inmobiliario y orientando políticas para mejorar la calidad de vida urbana. Los hallazgos representan un recurso valioso para la planificación estratégica y futura investigación en el mercado de la vivienda.

4.2. Future Improvements

Para evaluar y reforzar la hipótesis de que "el precio de una propiedad depende de forma lineal del número de habitaciones y del índice de vulnerabilidad del sector," se sugieren las siguientes mejoras:

Ampliación de Variables Relevantes: Incluir datos adicionales que complementen la hipótesis, evaluando cómo factores socioeconómicos y condiciones específicas del sector podrían impactar la relación lineal entre el precio, el número de habitaciones y la vulnerabilidad. Variables adicionales sugeridas incluyen:

1. **Tasa de desempleo:** Indicador del estado económico del sector, que puede influir en la vulnerabilidad y, en consecuencia, en el precio.
2. **Calidad de los servicios públicos:** La calidad y acceso a servicios como agua y electricidad puede reforzar el concepto de vulnerabilidad de un sector.

Estas mejoras permitirían evaluar la hipótesis con mayor precisión y profundizar en la relación lineal planteada, fortaleciendo la validez del modelo y la comprensión de cómo la vulnerabilidad del sector afecta el precio de las propiedades en combinación con el número de habitaciones.

5. Team Member Review and Comment

⟨ATTACH A TEAM PICTURE HERE⟩

NAME	REVIEW and COMMENT

--	--

6. Instructor Review and Comment

CATEGORY	SCORE	REVIEW and COMMENT
IDEA	__/10	
APPLICATION	__/30	
RESULT	__/30	
PROJECT MANAGEMENT	__/10	
PRESENTATION & REPORT	__/20	
TOTAL	__/100	